

Pedro Isasi

Departamento de Informática
Universidad Carlos III de Madrid

Optimización de conjuntos de datos para ML

Introducción

- El aprendizaje supervisado es una tarea de aprendizaje automático en el que se persigue obtener un modelo que sea capaz de mapear datos de entrada a una salida, denominada «predicción».
- Formalmente, sean:
  - $X \in M_{n \cdot m}(\Re)$ una matriz de atributos con m instancias y n atributos
  - $y \in \Re^m$ un vector de salidas con m instancias
- Buscamos obtener un modelo M tal que $\hat{y} = M(x)$
- El modelo será bueno si $\hat{y} \approx y$

Introducción

- Sean $(x_1, x_2, ..., x_n)$ el conjunto de atributos de nuestro problema.
- Llamamos síntesis de atributos al proceso por el cual se introducen nuevos atributos $(z_1, z_2, ..., z_r)$ donde $z_i = f(x_1, x_2, ..., x_n)$
- La síntesis de atributos permite capturar nuevas relaciones «ocultas» entre los atributos de entrada.
- P. ej., si f_i es una función no lineal, entonces un modelo lineal podría aproximar mediante regresión relaciones no lineales
- Llamamos reducción de dimensionalidad al proceso por el cual el conjunto de atributos se reduce a $(z_1, z_2, ..., z_s)$ con $s < n$
- El caso donde $(z_1, z_2, ..., z_s) \subset (x_1, x_2, ..., x_n)$ recibe el nombre de selección de atributos.
- La reducción de dimensionalidad permite mejorar el rendimiento de algunos modelos y, en ciertas ocasiones, prevenir el sobreajuste

Objetivo

- Se busca desarrollar un sistema de optimización de conjuntos de datos, que permita obtener una mejora en el proceso de aprendizaje supervisado
- Los estudiantes emplearán las técnicas de computación evolutiva que prefieran con el fin de realizar síntesis de atributos y la reducción de la dimensionalidad
- Se entregará a los estudiantes dos conjuntos de datos:
  - (X_y, y_t) será un conjunto de datos de entrenamiento
  - (X_v, y_v) será un conjunto de datos de validación / test.
- En ambos conjuntos, todos los valores serán números reales (regresión).
- Los estudiantes desarrollarán un programa v que, recibiendo (X_t, y_t), sea capaz de aprender una serie de transformaciones que transforme X_t en X'_t
- A la matriz X'_t la denominaremos matriz de atributos optimizada.

Objetivo

- Sea $\mathcal{P}$ el programa desarrollado, tal que $X'_t = \mathcal{P}(X_t)$ y $X'_v = v(X_v)$
- Sea M un modelo de regresión arbitrario entrenado con (X_t, y_t) cuyo error medio absoluto sobre el conjunto de validación será $e = |y_v - M(X_v)|$
- El programa será exitoso si el mismo modelo M, entrenado con el conjunto (X'_t, y_t), consigue un error absoluto en validación de $e' = |y_v - M(X'_v)|$ tal que $e' < e$

Evaluación

- Se entregará:
  - Un poster esquematizando la solución propuesta y los experimentos realizados
  - Una memoria breve conteniendo únicamente los resultados obtenidos y el análisis de los mismos